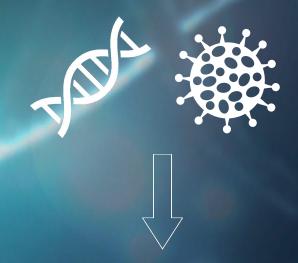




I dati biologici

Le sequenze biologiche sono memorizzate in file in formato Multi-FASTA



Formato Multi-FASTA

>NG_008679.1:5001-38170 Homo sapiens paired box 6 (PAX6)
ACCCTCTTTCCTTATCATTGACATTTAAACTCTGGGGCAGGTCCTCGCGTAGAACGCGGCTGTCAGATCT
GCCACTTCCCCTGCCGAGCGGCGGTGAGAAGTGTGGGAACCGGCGCTGCCAGGCTCACCTGCCTCCCGC
CCTCCGCTCCCAGGTAACCGCCCGGGCTCCGGCCCCGGCCCGGGCCTCGGGGCCCGCGGGGCCTCTCCGCTG
CCAGCGACTGCTGTCCCCAAATCAAAGCCCGCCCCAAGTGGCCCCGGGGCTTGATTTTTGCTTTTAAAAG
GAGGCATACAAAGATGGAAGCGAGTTACTGAGGGAGGGATAGGAAGGGGGGTGGAGGAGGACTTGTCTT
TGCCGAGTGTGCTCTTCTGCAAAAAGTAGCAAAATGTTCCACTCCTAAGAGTGGACTTCCAGTCCGGCCCT
GAGCTGGGAGTAGGGGGCGGGAGTCTGCTGCTGCTGCTGCTAAAGCCACTCCGCGACCGCGAAAAATGCA
GGAGGTGGGGACGCACTTTGCATCCAGACCTCCTTCTGCATCGCAGTTCACGACATCCACGCTTGGGAAAG
TCCGTACCCGCGCCCTGGAGCGCTTAAAGACACCCTGCCGCGGGTCGGGCGAGGTGCAGCAGAAGTTTCCC
GCGGTTGCAAAGTGCAGATGGCTGGACCGCAACAAAGTCTAGAGATGGGGTTCGTTTCTCAGAAAAGACGC

Il processo di annotazione

File Multi-FASTA



Informazioni delle sequenze simili alle sequenze del file Multi-FASTA

Il processo di annotazione

Software di annotazione











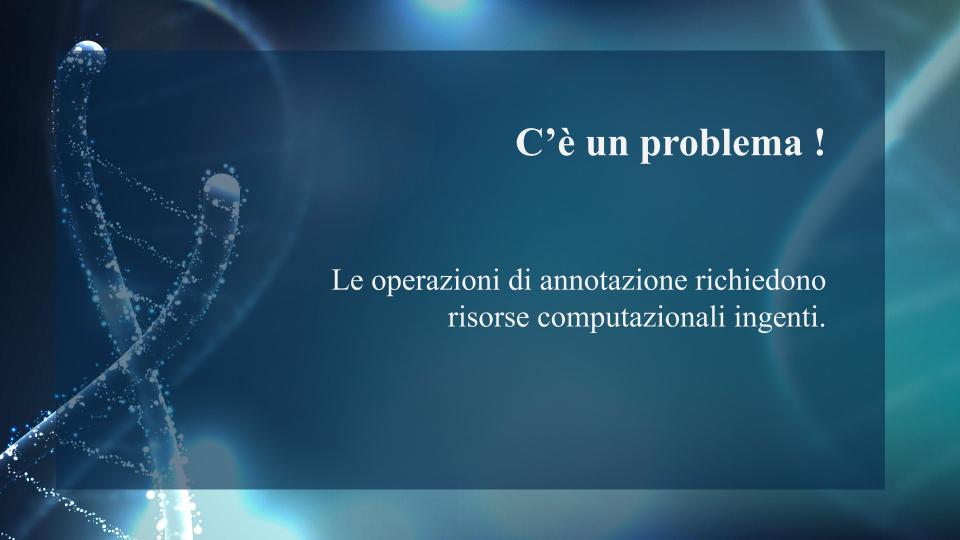




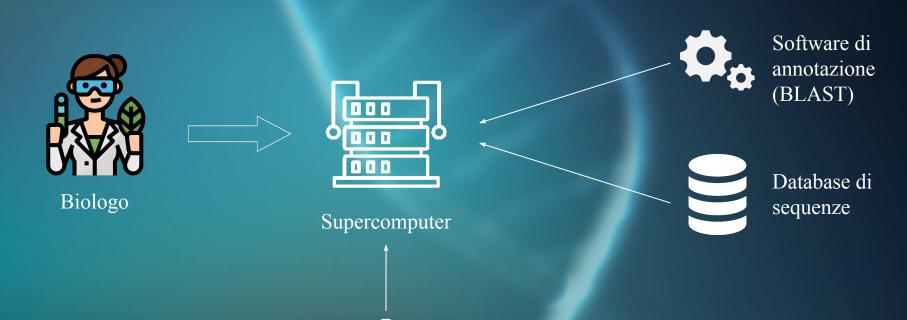
Risultati



Database di sequenze



I supercomputer



workload manager



I calcoli effettuati durante il processo di annotazione possono richiedere lo stesso molto tempo.



Funzionamento ad alto livello dell'algoritmo

Qual'è l'idea?



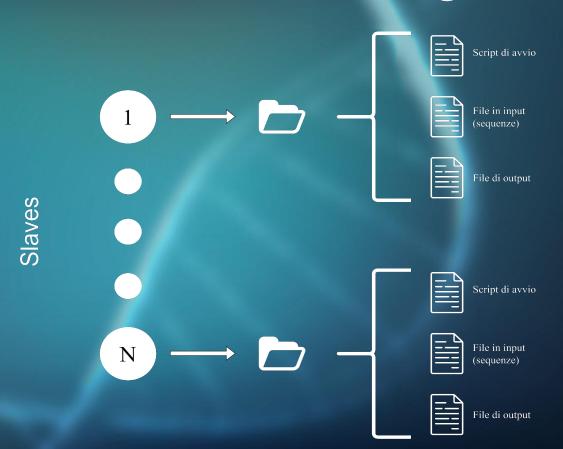


Vantaggi di questo approccio

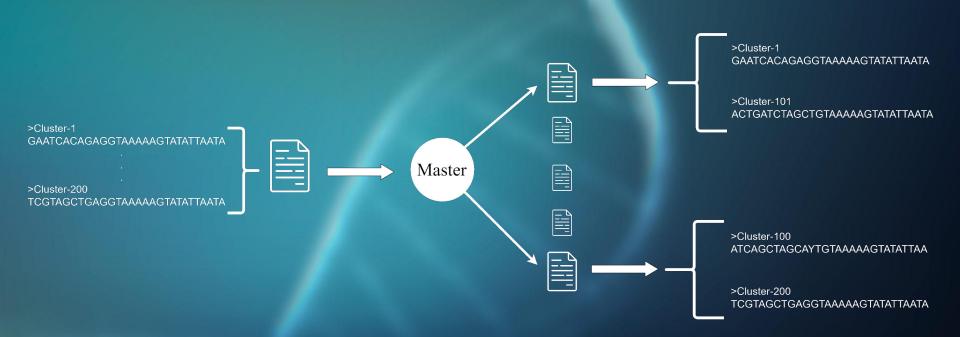
Tempi di esecuzione notevolmente ridotti.

• Possibilità di bypassare i limiti temporali imposti dallo scheduler.

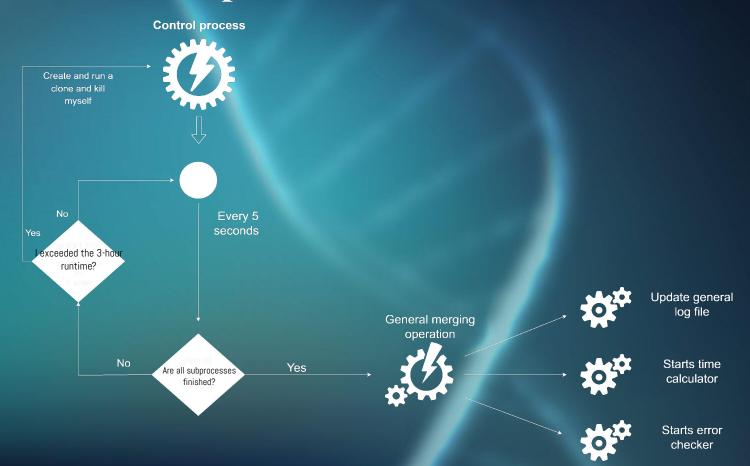
Cosa avviene in dettaglio



Cosa avviene in dettaglio



Il processo di controllo



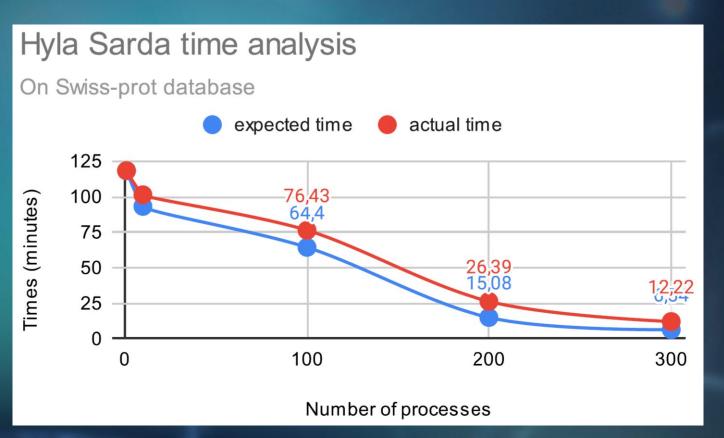


Benchmark e analisi sui tempi di esecuzione dell'applicazione

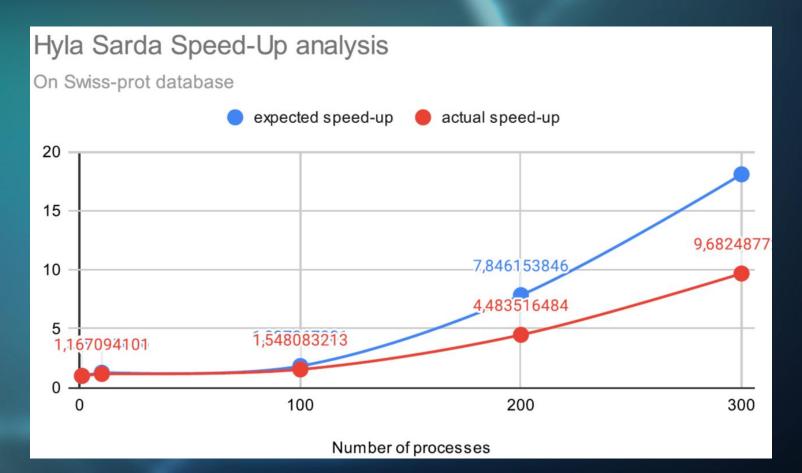
Analisi del trascrittoma di Hyla sarda

HYLA SARDA					
Sequences	Processes	Diamond	Database	Expected time (minutes)	Actual time (minutes)
1295741	1	yes	Swiss-Prot	118,32	118,32
1295741	10	yes	Swiss-Prot	93,21	101,38
1295741	100	yes	Swiss-Prot	64,4	76,43
1295741	200	yes	Swiss-Prot	15,08	26,39
1295741	300	yes	Swiss-Prot	6,54	12,22

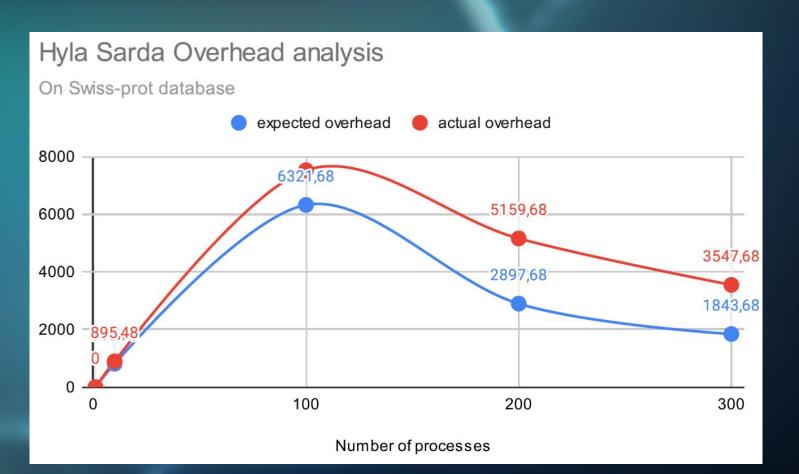
Grafico dei tempi di esecuzione



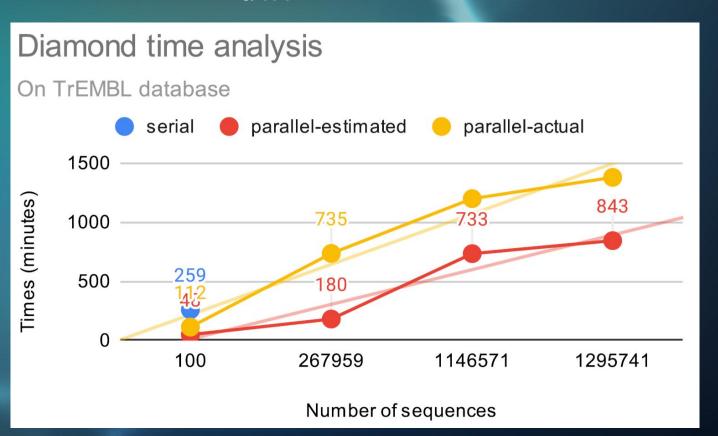
Speed-Up



Overhead



Benchmark sulla banca dati TrEMBL





Interfacce

Pannello di configurazione





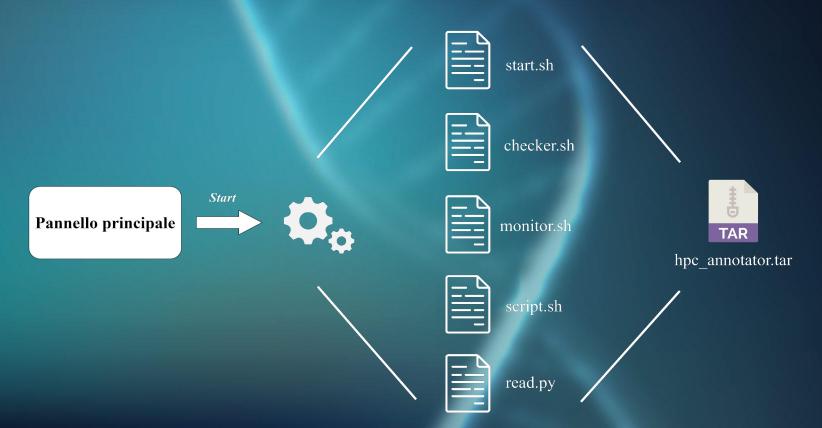
Database json di configurazione

Acquisizione del file json

Pannello principale



Funzionamento dell'interfaccia





Jupyter notebook per il post-processing dei dati di annotazione

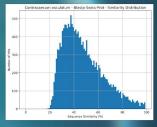
Generazione di report e grafici

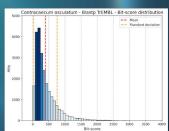


annotazione

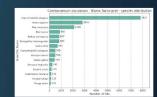


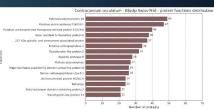
Notebook post-processing





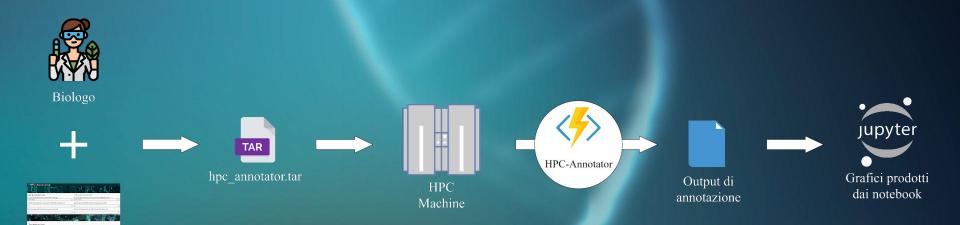








Pipeline bioinformatica



Interfaccia



L'intero software è disponibile con licenza gratuita ed open-source a questo indirizzo:

https://github.com/lorenzo-arcioni/HPC-Annotator

Candidato: Lorenzo Arcioni

Responsabile: Tiziana Castrignanò Corresponsabile: Paolo Bottoni